

UNIVERSIDAD CENTRAL DE VENEZUELA
FACULTAD DE CIENCIAS
ESCUELA DE COMPUTACIÓN
ASIGNATURA: CALCULO CIENTÍFICO
SEMESTRE: I-2026

TALLER II

Autor:

Anthony Javier Alvarado Rodriguez

27.321.522

1. Introducción:

El estudio de la variabilidad genética en poblaciones humanas se fundamenta en el análisis de Polimorfismos de Nucleótido Único (SNPs). Debido a que el número de sitios genéticos ($m = 100$) suele superar al número de individuos ($n = 30$), los datos presentan una alta dimensionalidad. En este informe se implementa el Análisis de Componentes Principales (PCA) mediante la Descomposición en Valores Singulares (SVD) para transformar la matriz de genotipos en un mapa bidimensional de ancestría.

Los genotipos se encuentran codificados discretamente según el número de copias de la variante mutada: 0 para el homocigoto de referencia (AA), 1 para el heterocigoto (Aa) y 2 para el homocigoto variante (aa).

2. Metodologia Numerica y Algoritmica:

2.1. Estimación de Frecuencias y Filtrado

Para cada SNP j , se calcula la frecuencia del alelo variante p_j recorriendo las observaciones de los n individuos de manera vertical mediante la expresión:

$$p_j = \frac{\sum_{i=1}^n G_{i,j}}{2n} \quad (1)$$

Aquellas columnas donde $p_j = 0$ o $p_j = 1$ deben ser descartadas del análisis para evitar singularidades matemáticas (divisiones por cero) en la etapa de normalización. En mi ejecución, las 100 columnas presentaron variabilidad, reteniéndose el conjunto de datos íntegro. Es decir, no se eliminó ninguna columna.

2.2. Normalización de Patterson

Con el fin de mitigar el sesgo provocado por la disparidad en las frecuencias de las mutaciones, se aplica la normalización basada en el modelo de Wright-Fisher. Cada elemento de la matriz original G se transforma en $\tilde{G}_{i,j}$ mediante:

$$\tilde{G}_{i,j} = \frac{G_{i,j} - 2p_j}{\sqrt{2p_j(1 - p_j)}} \quad (2)$$

Este centrado y escalado asegura que cada sitio genético contribuya equitativamente a la varianza total del sistema, permitiendo que las variantes raras tengan un peso estadístico comparable al de las comunes.

2.3. Factorización SVD y Proyección

Se realiza la Descomposición en Valores Singulares reducida de la matriz normalizada $\tilde{G}$:

$$\tilde{G} = U\Sigma V^T \quad (3)$$

Donde las coordenadas de los individuos en el espacio de las componentes principales se obtienen proyectando la matriz sobre sus vectores propios izquierdos ponderados por sus respectivos valores singulares:

$$PC = U\Sigma \quad (4)$$

3. Resultados de las pruebas:

3.1. Gráfico de Dispersión de Ancestría

En la Figura 1 se presenta la proyección de los individuos en el plano coordenado PC_1 vs PC_2 . El eje horizontal (PC_1) abarca un rango aproximado de $[-10, 10]$ capturando la mayor dispersión de los datos, mientras que el eje vertical (PC_2) se distribuye entre $[-8, 6]$.




Figura 1: Mapa de ancestría genética de los 30 individuos basado en PC_1 y PC_2 .

3.2. Análisis de Mezcla Genética

Al inspeccionar la distribución geométrica en la Figura 1, se evidencia la formación de dos grandes grupos diferenciados en los extremos de la primera componente principal (PC_1). Estos cúmulos representan poblaciones ancestrales de referencia que se desarrollaron bajo relativo aislamiento geográfico. Sin embargo, se observa de manera clara la existencia de individuos situados en la región intermedia del plano, fuera de los núcleos densificados. En términos de su historia genética, esta disposición lineal intermedia representa un proceso de mezcla migratoria o mestizaje. Estos individuos poseen un genoma híbrido compuesto por combinaciones lineales de las frecuencias alélicas de ambos grupos parentales, reflejando un flujo génico histórico o reciente entre las dos poblaciones originarias. Por otro lado, la concentración de la mayoría de la muestra en la región central de la segunda componente principal (PC_2), con solo unos pocos individuos dispersos hacia sus extremos, sugiere que la variabilidad secundaria es homogénea para la mayor parte de

la población estudiada, aislando en los extremos de dicho eje únicamente variaciones genéticas secundarias o subestructuras menores.

4. Conclusiones

La implementación de la SVD demostró ser una herramienta robusta y numéricamente estable para el procesamiento de datos biológicos de alta dimensionalidad. A través de la normalización de Patterson, el PCA logró filtrar el ruido de fondo y condensar la información genética estructural en solo dos dimensiones, permitiendo discernir con precisión tanto las líneas de ancestría puras como los perfiles de mezcla de la muestra analizada.