

Taller 4: El Algoritmo PageRank de Google

Álgebra Lineal, Cadenas de Markov y Grafos

Anthony Javier Alvarado Rodríguez

26 de junio de 2026

1. Introducción

El algoritmo PageRank, diseñado por Larry Page y Sergey Brin, es el pilar fundamental que permitió a Google organizar la web. Su premisa es que la importancia de una página no depende solo de cuántos enlaces recibe, sino de la relevancia de las páginas que la apuntan.

Matemáticamente, el PageRank es el autovector principal de una matriz estocástica que representa la probabilidad de que un usuario aleatorio se encuentre en una página determinada [1]. En este informe se analiza la implementación computacional de dicho algoritmo utilizando el Método de las Potencias sobre una red propia de 6 nodos.

2. Fundamento Matemático

Representamos la web como un grafo dirigido donde cada nodo es una página y cada arista un enlace. Sea $n = 6$ el número de páginas en nuestra red experimental.

2.1. La Matriz de Transición M

Definimos C_j como el número de enlaces salientes (grado de salida) de la página j . La matriz de transición $M \in \mathbb{R}^{n \times n}$ se construye inicialmente como:

$$M_{ij} = \begin{cases} \frac{1}{C_j} & \text{si existe un enlace de } j \text{ a } i \\ 0 & \text{en otro caso} \end{cases} \quad (1)$$

Para los "sumideros" (páginas donde $C_j = 0$), la probabilidad se reparte equitativamente entre todas las páginas de la red, es decir, se reemplaza la columna correspondiente por valores de $\frac{1}{n}$, garantizando que la matriz sea estocástica por columnas.

2.2. El Factor de Amortiguamiento y la Matriz G

Introducimos el factor de amortiguamiento $d = 0,85$, que representa la probabilidad de que un usuario continúe haciendo clic en los enlaces existentes. La Matriz de Google G se define como:

$$G = dM + \frac{1-d}{n}J \quad (2)$$

donde J es una matriz de unos de tamaño $n \times n$. Esta modificación garantiza que la matriz sea irreducible y aperiódica, asegurando por el Teorema de Perron-Frobenius la existencia de un autovector único asociado al autovalor $\lambda = 1$ [2].

3. Metodología: El Método de las Potencias

Debido al tamaño masivo de la web, el cálculo de autovectores mediante el polinomio característico es inviable. En su lugar, se utiliza el Método de las Potencias, un proceso iterativo definido por:

$$v^{(k+1)} = Gv^{(k)} \quad (3)$$

donde v es el vector de rangos inicializado equitativamente de forma uniforme ($v_i^{(0)} = \frac{1}{n}$). El proceso converge cuando la norma de la diferencia entre iteraciones consecutivas cumple con el criterio de parada basado en la tolerancia $\epsilon = 10^{-8}$:

$$\|v^{(k+1)} - v^{(k)}\|_1 < 10^{-8} \quad (4)$$

4. Tareas del Proyecto

4.1. Diseño del Grafo

Se propuso una red de 6 nodos (A, B, C, D, E, F) que contiene 8 relaciones explícitas: un ciclo principal ($A \rightarrow B \rightarrow C \rightarrow A$), un nodo sumidero (D , donde $C_D = 0$) alimentado por C y E , conexiones periféricas ($F \rightarrow A$, $F \rightarrow E$) y una conexión de escape hacia la periferia ($B \rightarrow F$).

La matriz de adyacencia estructurada en el código (donde las columnas representan el origen y las filas el destino) es:

$$A = \begin{pmatrix} 0 & 0 & 1 & 0 & 0 & 1 \\ 1 & 0 & 0 & 0 & 0 & 0 \\ 0 & 1 & 0 & 0 & 0 & 0 \\ 0 & 0 & 1 & 0 & 1 & 0 \\ 0 & 0 & 0 & 0 & 0 & 1 \\ 0 & 1 & 0 & 0 & 0 & 0 \end{pmatrix} \quad (5)$$

4.2. Implementación en Python

El algoritmo se desarrolló de manera secuencial en Google Colab. Tras procesar la matriz y aplicar las correcciones, el método de las potencias convergió exitosamente en 44 iteraciones. Los resultados numéricos obtenidos se presentan en la Tabla 1.

Cuadro 1: Ranking y puntuación de PageRank por página.

Lugar	Página (Nodo)	PageRank
1°	D	0.215001
2°	B	0.205887
3°	A	0.176975
4°	C	0.142960
5°	F	0.142960
6°	E	0.116217

4.3. Análisis

El taller plantea la interrogante de por qué una página con pocos enlaces entrantes podría obtener un ranking mayor que una con muchos.

Los resultados experimentales ofrecen una justificación matemática directa mediante el comportamiento del Nodo D. El Nodo D es un sumidero que únicamente recibe enlaces directos del Nodo C y del Nodo E. A pesar de contar con escasa conectividad entrante en comparación con la estructura cíclica de la red, se posiciona en el primer lugar del ranking general (0,215001).

Esto ocurre porque el PageRank no evalúa la cantidad bruta de enlaces entrantes, sino la relevancia acumulada de los nodos de origen. El Nodo D recibe un enlace del Nodo C, el cual a su vez viene respaldado por la alta densidad de flujo del ciclo principal y la influencia del Nodo B. Al transferirse este prestigio concentrado hacia D, y al carecer este de enlaces salientes propios para dispersar la probabilidad (actuando como un pozo de acumulación antes de la amortiguación), su puntuación se eleva por encima de los componentes más conectados de la red. Matemáticamente, un solo enlace proveniente de una fuente de alta autoridad aporta un valor significativamente mayor que múltiples enlaces provenientes de nodos periféricos o irrelevantes.

Referencias

- [1] L. Page, S. Brin, R. Motwani, y T. Winograd. *The PageRank citation ranking: Bringing order to the web*. Stanford InfoLab, 1999.
- [2] A. M. Langville y C. D. Meyer. *Google's PageRank and beyond: The science of search engine rankings*. Princeton University Press, 2011.